

Práctica Dirigida 5

Mg. Sc. J. Eduardo Gamboa U.

Pregunta 1

El dataset PD5 - datos1.xlsx representa a 50 pacientes atendidos en una clínica privada durante el periodo de una semana. Contiene variables como la edad, sexo, tipo de seguro, tiempo de espera, entre otras.

Algunos pacientes con alto nivel de dolor no responden a algunas preguntas, por lo que hay algunas celdas vacías. Así también, pacientes muy insatisfechos, apurados, o por algún otro motivo, no responden a la pregunta de satisfacción. Finalmente, también existen valores perdidos debido a errores administrativos o fallas del sistema.

1. Leer el archivo PD5 - datos1.xlsx, almacenándolo como datos1
2. Aplicar la función `na.omit` y explicar el resultado.
3. Aplicar la función `complete.cases`, almacenando el resultado en un objeto de nombre `perdidos`. Luego, explicar qué significa `perdidos[1:5]`.
4. Aplicar la función `md.pattern` y explicar el resultado.
5. Aplicar la función `gg_miss_upset` e indique si las siguientes afirmaciones son verdaderas o falsas:
 - a. La variable con más valores perdidos es IMC
 - b. Hay 15 filas donde la variable teleconsulta previa tiene valores perdidos.
 - c. El patrón más frecuente de dos variables con valores perdidos al mismo tiempo es `glucosa_ayunas_mg_dl` y `teleconsulta_previa`
 - d. La variable presión sistólica tiene 7 valores perdidos.

A menos que se indique lo contrario, resolver cada una de las siguientes preguntas de manera independiente, es decir una no es continuación de la otra:

6. Construir una nueva tabla que contenga únicamente el identificador del paciente, edad, sexo y zona.

7. Generar una tabla con todas las variables excepto ingreso y seguimiento.
8. Extraer las edades de todos los pacientes como un vector.
9. Cambiar el nombre de la variable edad a edad_años.
10. Renombrar simultáneamente id como id_paciente, fecha como fecha_consulta e imc como indice_masa_corporal.
11. Crear una variable llamada edad_meses que represente aproximadamente la edad del paciente en meses.
12. ¿Qué ocurre con la variable edad después de resolver la pregunta anterior?
 - a) Se elimina
 - b) Se reemplaza por edad_meses
 - c) Se conserva y se añade edad_meses
 - d) Se transforma automáticamente a texto
13. Transformar la variable sexo, originalmente codificada como “M” y “F”, para que contenga “Masculino” y “Femenino”.
14. Crear una variable grupo_edad con las siguientes categorías:
 - Menor de 30 años: “Joven”
 - De 30 a 59 años: “Adulto”
 - 60 años o más: “Adulto mayor”
15. Renombrar id como codigo, crear grupo_edad clasificando a los pacientes en menores de 60 años y 60 años o más, y finalmente conservar únicamente codigo, edad, grupo_edad, sexo e imc.

Códigos que pueden ser de ayuda:

```
datos1 <- read_excel('...', skip = ...)
datos1 |> mice::md.pattern(rotate.names = TRUE)
library(dplyr)
```

Pregunta 2

El archivo PD5 - datos2.xlsx contiene datos sobre 100 clientes de una plataforma de comercio electrónico, así como 400 observaciones de parcelas agrícolas monitoreadas con sensores. Cada uno de estos datasets se encuentra en una hoja distinta.

1. Leer los 30 primeros datos de los clientes de la plataforma de comercio electrónico.
2. Leer los datos contenidos en el rango A1:H25 de la hoja AGRO.

Resolver las siguientes preguntas usando el conjunto de datos completo disponible en la hoja ECOMMERCE

3. GenerAR una tabla que contenga únicamente el identificador del cliente, segmento, plan, antigüedad y región.
4. GenerAR una tabla que contenga todas las variables excepto ingreso_reportado y uso_app_min_7d.
5. Extraer los valores de nps como un vector.
6. Cambiar el nombre de antigüedad_meses por meses_cliente.
7. Crear una variable nps_alto que tome el valor “Sí” cuando el NPS sea igual o superior a 50 y “No” cuando sea menor de 50.
8. Crear una variable uso_app que clasifique a los clientes de la siguiente manera:
 - Menos de 60 minutos → “Bajo”
 - De 60 a 119 minutos → “Medio”
 - 120 minutos o más → “Alto”